

EVALUACIÓN PARCIAL N°1

Diseño de Solución con LLM y RAG

Proyecto: Hotel El Almendro

Carrera: Ingeniería en Informática

Asignatura: Ingeniería de Soluciones con Inteligencia Artificial

Equipo de Proyecto:

Matias Ignacio Loyola Cornejo - Matias Manuel Cisternas Stuardo

Docente: Francisca Valenzuela

Fecha: 7 de Septiembre de 2026

Índice

Índice	1
Resumen	2
1. Análisis del caso organizacional	2
1.1 Contexto y problema	2
1.2 Objetivo de la intervención	2
1.3 Datos, requerimientos y restricciones	3
2. Formulación de prompts	4
2.1 Prompt del sistema	4
2.2 Plantilla de consulta y control de salida	5
3. Diseño e implementación del pipeline RAG	5
4. Arquitectura de la solución	6
4.1 Componentes y flujo	7
5. Documentación técnica y estrategia de validación	7
6. Decisiones de diseño y trazabilidad	8
7. Conclusiones y reflexiones individuales	8
7.1 Conclusión general	8
7.2 Reflexiones individuales	9
Referencias	10

Resumen

El presente informe describe el diseño e implementación de un prototipo de agente inteligente de soporte técnico para el área de Obras, Mantenimiento y Mejoras (OMM) de Hotel El Almendro. La solución utiliza una arquitectura Retrieval-Augmented Generation (RAG) para consultar documentación técnica en formato PDF mediante lenguaje natural. El prototipo fue desarrollado en Python y Google Colab, utilizando RecursiveCharacterTextSplitter para la segmentación, mistral-embed para generar embeddings y FAISS como índice vectorial. Para la generación de respuestas se utilizó el modelo mistral-7b-instruct-v0.2, configurado con temperature=0.1. En las pruebas realizadas se procesó un manual técnico de caldera, generando 52 fragmentos y 52 vectores de 1024 dimensiones. El sistema logró responder consultas respaldadas por el documento, identificar la fuente utilizada y rechazar consultas cuya información no se encontraba disponible.

1. Análisis del caso organizacional

1.1 Contexto y problema

Hotel El Almendro utiliza actualmente múltiples planillas Excel para gestionar información del área OMM, lo que dificulta la centralización y la trazabilidad. Para esta evaluación de IA se toma un problema acotado y diferente del desarrollo integral de Capstone: la búsqueda técnica en terreno. El personal debe revisar manuales PDF, fichas técnicas, protocolos internos y documentación oficial de fabricantes para resolver dudas operativas, generando demoras y riesgo de utilizar información incompleta o desactualizada.

1.2 Objetivo de la intervención

Diseñar un agente inteligente de soporte técnico que permita consultar documentación oficial de OMM mediante lenguaje natural, recuperando evidencia relevante con RAG y entregando una respuesta acompañada de su fuente. Como criterios de aceptación, el prototipo deberá identificar la fuente utilizada en las respuestas sustentadas, indicar explícitamente cuando no exista información suficiente y recuperar información semánticamente relacionada aunque la consulta no utilice exactamente las mismas palabras del documento. La evaluación considerará métricas de recuperación y generación como Context Precision, Context Recall, Faithfulness y Answer Relevancy, además del tiempo de respuesta del sistema.

1.3 Datos, requerimientos y restricciones

Elemento	Contenido para el caso	Condición de uso
Fuentes internas	Manuales PDF, fichas técnicas, protocolos internos y documentación técnica entregada por El Almendro. Las planillas Excel podrán utilizarse posteriormente como fuente complementaria.	Documentos previamente revisados y autorizados.
Fuentes externas	Manuales y fichas oficiales de fabricantes; normativa pública aplicable validada por OMM.	No usar web abierta en tiempo real como evidencia.
Requerimientos	Consulta en lenguaje natural, recuperación semántica, respuesta con fuente, aviso de ausencia de información.	La respuesta debe permanecer dentro del contexto recuperado.
Restricciones	Privacidad, documentos potencialmente desactualizados, formatos heterogéneos y riesgo de alucinación.	Metadatos de origen/fecha/versión y validación humana de documentos.

Nota de validación: Para comprobar técnicamente el funcionamiento del prototipo se utilizó temporalmente un manual técnico público de una caldera Rinnai. Este documento se utilizó únicamente como fuente de prueba mientras se obtiene la documentación autorizada de El Almendro. La arquitectura permite posteriormente sustituir o complementar esta fuente con manuales, protocolos y fichas técnicas de la empresa.

2. Formulación de prompts

Para el prototipo se utilizará principalmente una estrategia zero-shot con role prompting y restricciones de salida. El modelo recibirá un rol especializado, una tarea explícita, el contexto recuperado y reglas que limiten el uso de información externa. Esta estructura busca reducir alucinaciones y mantener respuestas consistentes con la documentación disponible.

2.1 Prompt del sistema

Eres un asistente técnico del área de Obras, Mantenimiento y Mejoras (OMM) de Hotel El Almendro.

Responde únicamente utilizando la información incluida en el CONTEXTO recuperado.

No utilices conocimiento general para completar información que no aparezca en los documentos.

No inventes procedimientos, valores, frecuencias, repuestos, riesgos ni especificaciones técnicas.

Si el contexto no contiene información suficiente para responder, indica:

“No existe información suficiente en la documentación disponible”.

Si existe información suficiente, responde de forma breve y clara e identifica el documento utilizado como fuente.

Si existen datos contradictorios entre documentos, informa la contradicción y no selecciones una respuesta sin evidencia de vigencia.

CONTEXTO: {context}

PREGUNTA: {question}

FORMATO DE RESPUESTA:

Respuesta:

Fuente:

Estado de respaldo: suficiente / insuficiente

2.2 Plantilla de consulta y control de salida

Componente	Aplicación
Entrada	Pregunta del trabajador en lenguaje natural; opcionalmente área/equipo para filtrar metadatos.
Contexto	Hasta 3 fragmentos relevantes recuperados desde FAISS mediante búsqueda por similitud semántica, conservando metadatos del documento de origen.
Salida	Respuesta técnica, fuente utilizada y nivel de suficiencia. Si no hay respaldo: negativa explícita sin completar con conocimiento general.

3. Diseño e implementación del pipeline RAG

El pipeline se plantea en dos procesos: ingestión controlada de conocimiento y consulta. En la ingestión, los documentos autorizados se extraen, limpian y segmentan; cada fragmento conserva metadatos de trazabilidad. Luego se generan embeddings y se almacenan en una base vectorial. En consulta, la pregunta se transforma a embedding, se recuperan los fragmentos más similares y el LLM recibe exclusivamente ese contexto junto con las reglas del prompt.

Etapas	Configuración inicial del prototipo	Evidencia esperada
Entorno	Python ejecutado mediante Google Colab y credenciales almacenadas en Secrets.	Notebook ejecutado sin exponer API keys.
Carga	Documentos PDF mediante PyPDF, conservando nombre del documento y número de página como metadatos.	Documentos cargados y metadatos visibles.
Segmentación	RecursiveCharacterTextSplitter, chunk_size=350 y chunk_overlap=50	Conteo y muestra de chunks generados.
Embeddings	Mistral mistral-embed	Vectores generados correctamente.
Vector store	FAISS	Índice vectorial creado y consultable.
Recuperación	Retriever con k=3	Fragmentos relevantes recuperados para cada consulta.
Generación	LangChain + ministral-8b-2512, temperature=0.1	Respuesta generada utilizando el contexto recuperado.

4. Arquitectura de la solución

La arquitectura separa el procesamiento documental del proceso de consulta. Los documentos PDF son cargados mediante PyPDF y segmentados utilizando RecursiveCharacterTextSplitter. Cada fragmento se transforma en una representación vectorial mediante mistral-embed y se almacena en un índice FAISS. Ante una consulta, esta también se transforma en un embedding y se compara con los vectores almacenados para recuperar los tres fragmentos con mayor similitud. Posteriormente, LangChain coordina el envío de la pregunta, el contexto recuperado y el prompt restrictivo al modelo mistral-8b-2512, que genera la respuesta final e identifica la fuente utilizada.



4.1 Componentes y flujo

Capa de fuentes: documentos PDF internos y externos previamente autorizados. Cada archivo conserva metadatos que permiten identificar su procedencia.

Capa de procesamiento y recuperación: los documentos son segmentados mediante RecursiveCharacterTextSplitter. Los fragmentos se transforman en vectores utilizando mistral-embed y se almacenan en FAISS. El retriever recupera los tres fragmentos con mayor similitud semántica para cada consulta.

Capa de generación: LangChain coordina la consulta, el contexto recuperado y el prompt restrictivo. El modelo ministral-8b-2512, configurado con temperature=0.1, genera la respuesta final utilizando únicamente los fragmentos recuperados.

Capa de trazabilidad: la respuesta conserva información sobre el documento utilizado como fuente para permitir su posterior revisión.

5. Documentación técnica y estrategia de validación

La validación funcional se realizó sobre la recuperación de información y la generación de respuestas. Como marco conceptual se consideran las métricas Context Precision, Context Recall, Faithfulness y Answer Relevancy; sin embargo, en esta primera implementación se realizó una comprobación funcional y cualitativa mediante consultas controladas. Para las pruebas se utilizó un manual técnico de caldera en PDF. El procesamiento generó 32 páginas con contenido, 52 chunks y un índice FAISS compuesto por 52 vectores de 1024 dimensiones.

Prueba	Resultado obtenido
Información existente	Ante la pregunta sobre qué hacer antes del mantenimiento, recuperó la página 12 con similitud 0.9089 y respondió correctamente que se debe desenchufar la caldera, identificando documento y página.
Información inexistente	Ante una consulta sobre el precio actual de una caldera, el agente indicó que no existía información suficiente y marcó el respaldo como insuficiente.
Recuperación semántica	Para una consulta sobre limpieza del filtro, FAISS recuperó tres fragmentos y encontró dentro del Top-3 la sección de Limpieza y Mantenimiento de la página 12.

6. Decisiones de diseño y trazabilidad

Decisión	Fundamento
RAG en lugar de un LLM aislado	Permite fundamentar las respuestas en documentación proporcionada al sistema y reducir respuestas no respaldadas.
LangChain	Permite integrar carga de documentos, segmentación, embeddings, recuperación y generación dentro de un mismo flujo.
FAISS	Se utilizará como índice vectorial para almacenar embeddings y ejecutar búsquedas por similitud semántica.
Mistral mediante API	Permite utilizar los mismos modelos y patrón de conexión trabajado en los ejercicios de la asignatura.
mistral-embed	Se utilizará para generar los embeddings de documentos y consultas.
ministral-8b-2512	Se utiliza como LLM para generar las respuestas finales a partir del contexto recuperado.
Metadatos y fuente	Permiten identificar el documento desde el cual se obtuvo la información y mejorar la trazabilidad.

Modelos utilizados: Para la implementación se utilizan dos modelos del proveedor Mistral. mistral-embed permite transformar los fragmentos de documentos y las consultas en representaciones vectoriales utilizadas durante la búsqueda semántica. ministral-8b-2512 se utiliza como modelo de lenguaje para generar la respuesta final a partir del contexto recuperado. Las credenciales son administradas mediante Secrets de Google Colab y no se almacenan directamente en el código ni en el repositorio.

7. Conclusiones y reflexiones individuales

7.1 Conclusión general

En conclusión, consideramos que la propuesta puede ayudar a solucionar un problema real del área de Obras, Mantenimiento y Mejoras de El Almendro, principalmente reduciendo el tiempo que se ocupa actualmente buscando información en distintos manuales, fichas técnicas y planillas. Las pruebas realizadas permitieron comprobar que un agente basado en LLM y RAG puede recuperar información relevante desde documentación técnica, generar respuestas respaldadas por la fuente e indicar cuando la información solicitada no se encuentra disponible.

7.2 Reflexiones individuales

Matias Loyola

Yo creo que este proyecto es una buena oportunidad para conocer de forma más práctica cómo funciona la inteligencia artificial y la función del RAG. Me parece interesante poder trabajar con documentos reales del hotel y lograr que el agente pueda buscar información dentro de ellos para responder consultas, siento que esto ayudará mucho a la empresa. Lo que espero es aprender más sobre cómo se conectan los modelos de lenguaje con otras herramientas y entender mejor cómo se puede aplicar este tipo de soluciones a problemas reales de una empresa.

Matias Cisternas

Yo pienso que lo más interesante de este proyecto es que estamos trabajando con una necesidad real de El Almendro y no con un caso inventado solo para la asignatura. Actualmente tienen información repartida en distintos archivos y eso hace que buscar algún dato técnico pueda tomar más tiempo del necesario. Por eso creo que usar un agente que pueda revisar esos documentos y entregar la información de forma más rápida puede ser bastante útil. También me interesa aprender mejor cómo funciona este proceso por dentro, cómo se preparan los documentos para que el sistema los pueda utilizar y cómo comprobar que las respuestas que entrega sean realmente correctas y confiables.

Referencias

Duoc UC. (2025). Evaluación Parcial N°1: Diseño de solución con LLM y RAG. Instrucciones y pauta de evaluación. Subdirección de Diseño Instruccional.

El Almendro. (s.f.). El Almendro, eco-hotel & eventos. Recuperado el 7 de septiembre de 2026, de <https://www.elalmendro.cl/>

Cordero, A. (2026). Sistema de Gestión de Tareas por Áreas OMM (Presentación de PowerPoint). Hotel El Almendro.

LangChain. (s.f.). Build a semantic search engine with LangChain. Recuperado el 7 de septiembre de 2026, de <https://docs.langchain.com/oss/python/langchain/knowledge-base>

OpenAI. (2026). ChatGPT herramienta de apoyo para organizar ideas, mejorar la redacción y orientar la estructura del informe. <https://chatgpt.com/>

Mistral AI. (s.f.). Mistral AI documentation. Recuperado el 17 de septiembre de 2026, de <https://docs.mistral.ai/>